Detección de clientes insatisfechos en Olist

Clasificación supervisada con variables del pedido y texto de las reseñas

Ingeniería de la Información · Tercer corte

PROBLEMA

¿Se puede identificar automáticamente a un cliente insatisfecho?

98.673

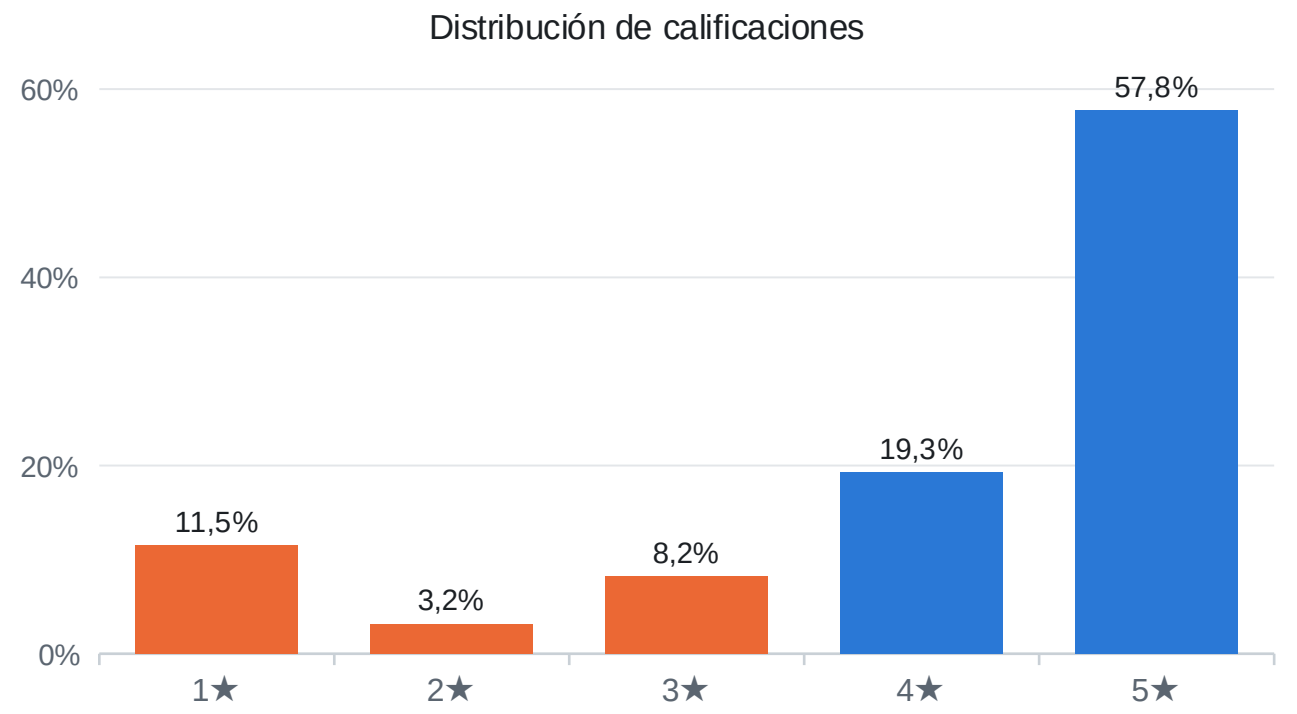
pedidos con reseña

9

tablas relacionadas: pedidos, reseñas, productos, pagos, clientes, vendedores…

22,9 %

de los clientes calificó con 1, 2 o 3 estrellas



Variable objetivo: insatisfecho = 1 si la reseña tiene de 1 a 3 estrellas (naranja), 0 si tiene 4 o 5 (azul).

Fuente: Brazilian E-Commerce Public Dataset by Olist (Kaggle), 2016-2018

PROCESO

El análisis siguió las cuatro etapas de la analítica de datos

1

Descriptiva

¿Qué pasó?

Cuántos clientes quedan insatisfechos, cuándo y dónde.

2

Diagnóstica

¿Por qué pasó?

Relación con retrasos, vendedores y el contenido de los comentarios.

3

Predictiva

¿Qué pasará?

Intento 1: variables del pedido.

Intento 2: texto de la reseña.

4

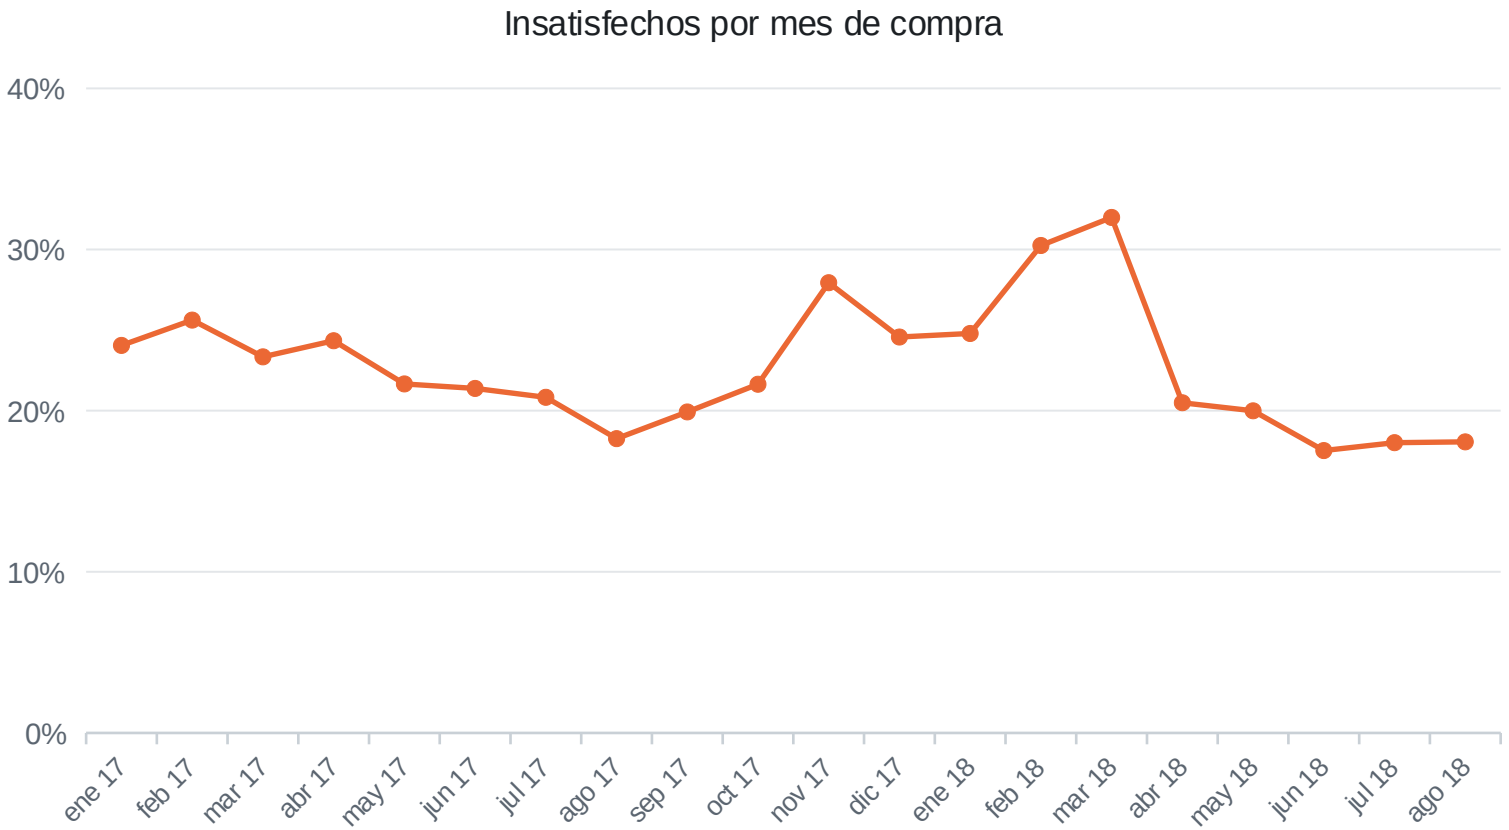
Prescriptiva

¿Qué hacer?

Acciones derivadas de los resultados.

La etapa predictiva necesitó dos intentos: el diagnóstico explica por qué el primero no era suficiente.

Casi 1 de cada 4 clientes queda insatisfecho, con picos en nov. 2017 y feb.-mar. 2018



Categoría

Muebles de oficina: 36,9 % de insatisfechos, la más alta.

Ubicación

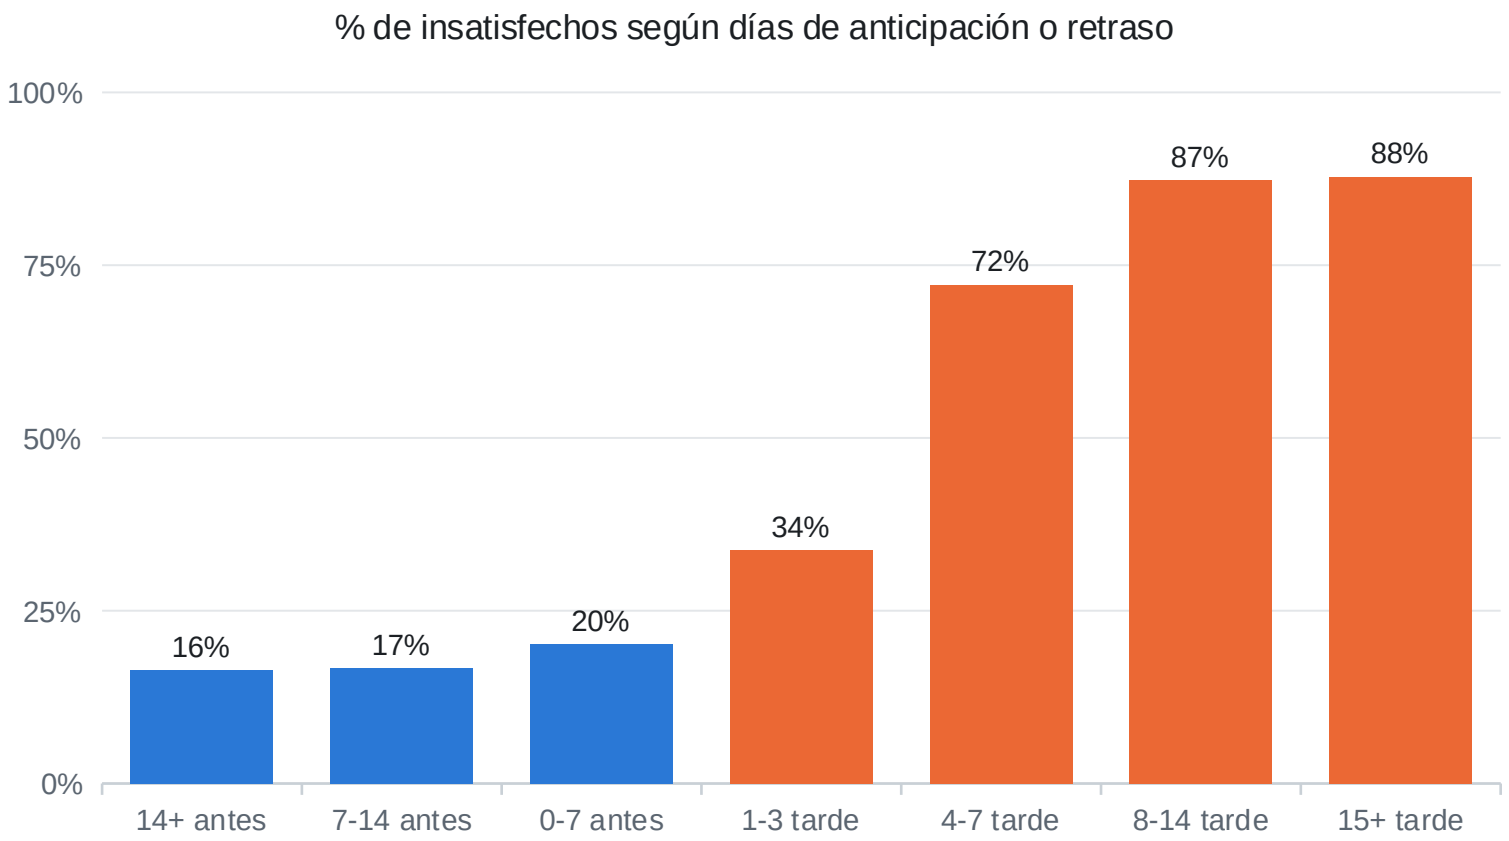
Ceará, Bahía y Río de Janeiro ≈ 29 %; São Paulo 20,6 %.

Comentarios

Los insatisfechos comentan casi el doble: 63,5 % frente a 34,7 %.

Meses con al menos 500 pedidos

Cuando el pedido llega tarde, la insatisfacción se multiplica casi por cuatro



17,2 % A tiempo

65,4 % Tarde

85,6 % No entregado

Los meses con más entregas tarde son los de mayor insatisfacción (correlación mensual de 0,73). También pesan los pedidos con varios vendedores (60,5 %) y el despacho tardío del vendedor (34,8 % frente a 20,4 %).

Días respecto a la fecha estimada de entrega informada al cliente

Pero 2 de cada 3 insatisfechos recibieron su pedido a tiempo



¿De qué se quejan los que recibieron a tiempo?

Pedido incompleto	**12,7 %**
Producto diferente a lo anunciado	**9,5 %**
Producto dañado o que no funciona	**8,1 %**
Calidad baja o falsificación	**7,4 %**

Conclusión del diagnóstico

Las variables del pedido explican la insatisfacción por retraso. La que viene del producto (incompleto, diferente, dañado) solo aparece en el comentario del cliente.

Palabras clave buscadas en 14.377 comentarios de clientes insatisfechos

Los dos intentos siguen el mismo procedimiento de clasificación

1

Variables

X: información de entrada

Y: insatisfecho (0/1)

2

Partición

80 % entrenamiento

20 % prueba, estratificada

3

Modelos

Decision Tree, Random Forest, KNN, regresión logística, MLP

4

Ajuste

Un hiperparámetro por modelo, elegido con validación

5

Evaluación

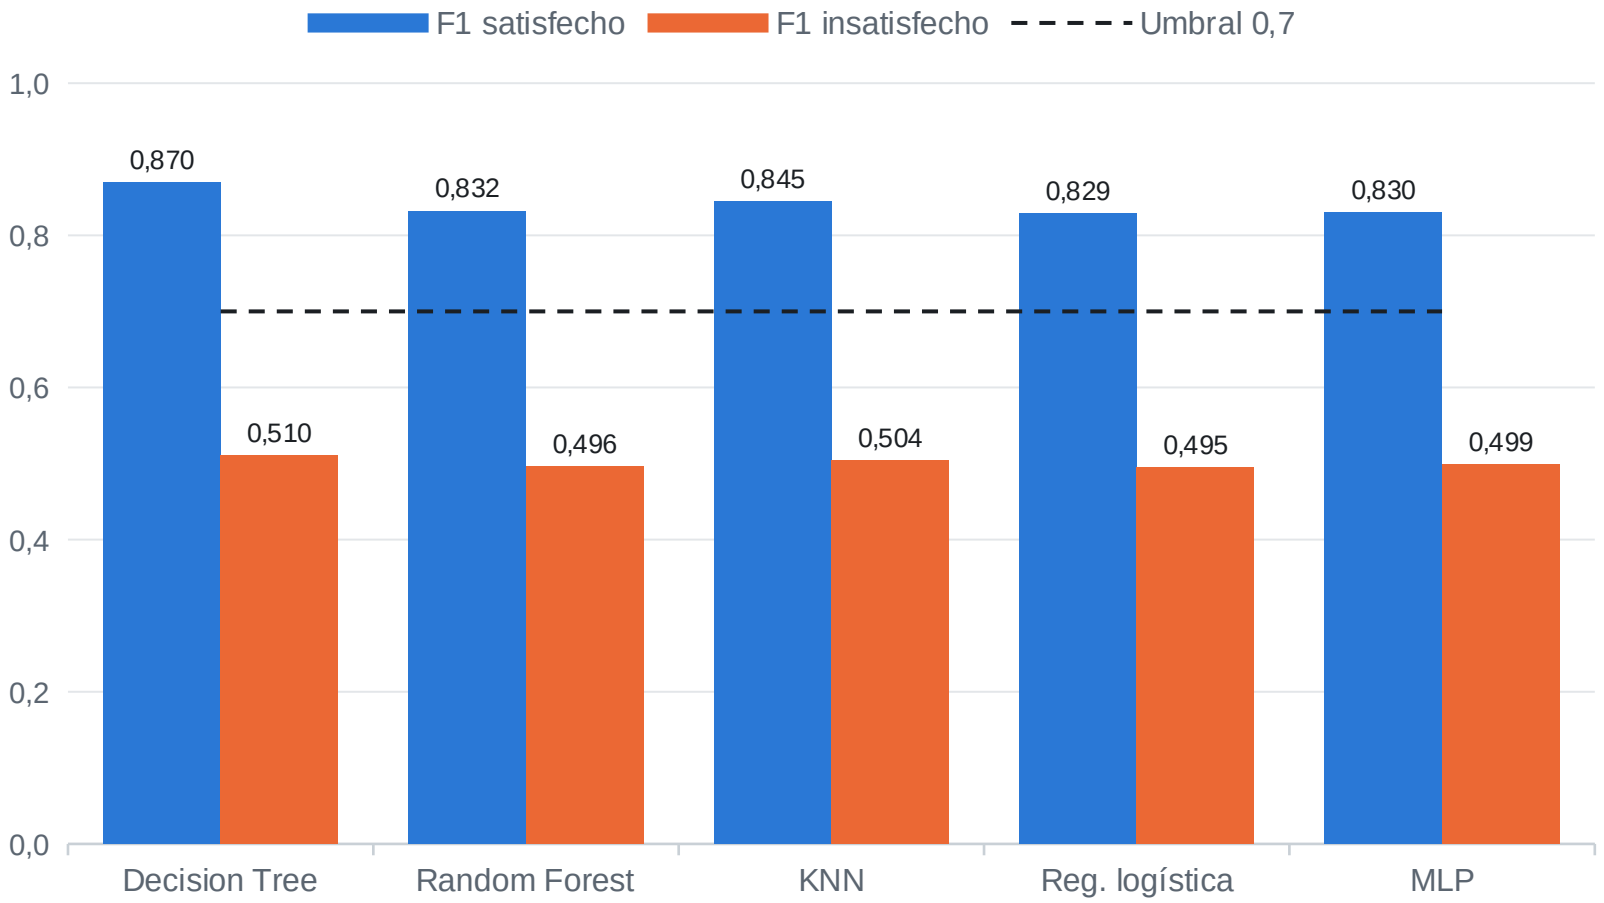
Matriz de confusión y F1 por clase en prueba



La validación se usa para escoger hiperparámetros; la prueba se usa una sola vez al final, para que siga siendo un examen con datos no vistos.

Criterio de aceptación: F1 > 0,7 en ambas clases

Intento 1: con variables del pedido, ningún modelo supera 0,7 en la clase insatisfecho



Mejor resultado

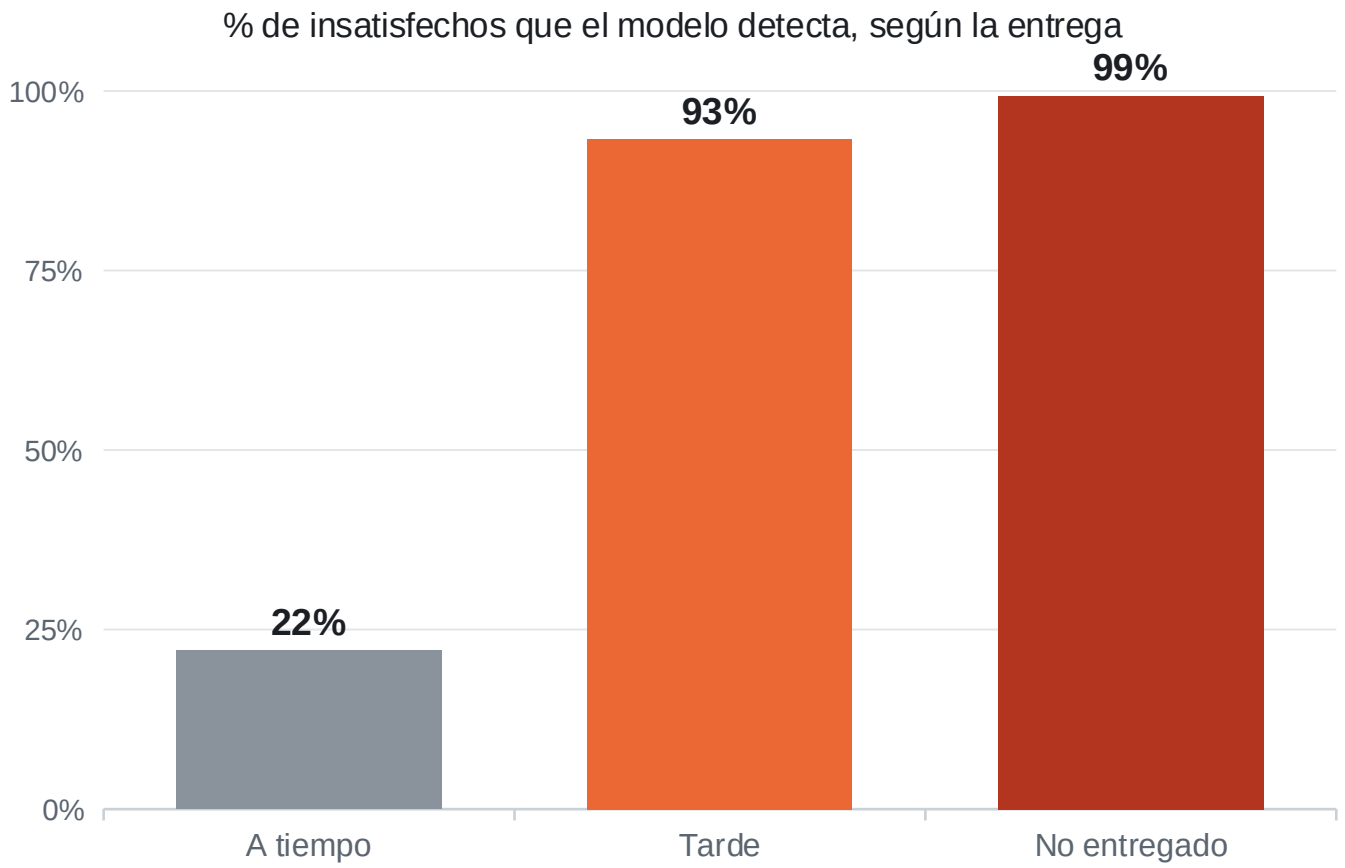
Decision Tree con max_depth = 5: F1 de 0,870 y 0,510.

Ajustar hiperparámetros no cambia el resultado

Todos los modelos quedan alrededor de 0,5. El árbol sin límite de profundidad memoriza y baja a 0,407 en validación.

13 variables: entrega, retraso, despacho, productos, vendedores, precio, flete, peso, distancia, cuotas, fotos. Entrenamiento balanceado por submuestreo.

El modelo detecta la insatisfacción por retraso, pero no la causada por el producto



Los insatisfechos que recibieron a tiempo son 67 % del total, y el modelo solo detecta 22 % de ellos.

Para esos pedidos, las variables no distinguen a un cliente satisfecho de uno insatisfecho. La limitación está en la información, no en el algoritmo.

Las variables más importantes del Random Forest son las de entrega: días de retraso y días de entrega real.

Recall de la clase insatisfecho del mejor modelo del intento 1, en el conjunto de prueba

Decisión: usar el comentario del cliente como variable de entrada

64 %

de los clientes insatisfechos deja un comentario, y ahí describen la causa de la queja.

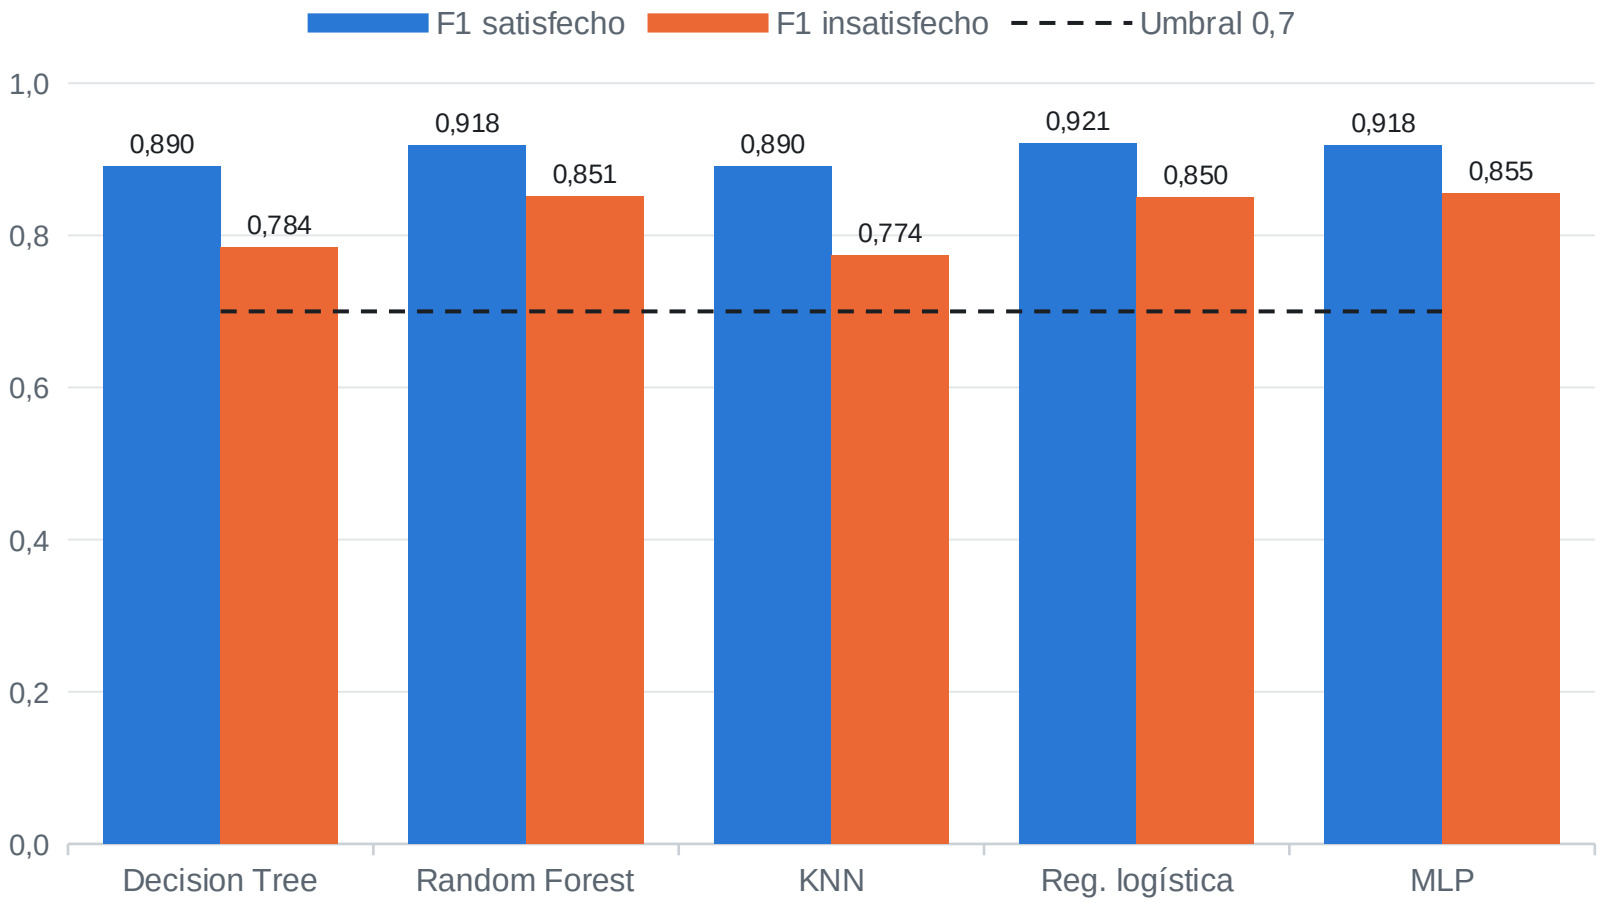
40.775 pedidos con comentario (35 % insatisfechos). Cambia la pregunta: ¿este comentario corresponde a un cliente insatisfecho? Es el caso de uso de priorizar la atención de reseñas negativas.

Bolsa de palabras: cada palabra es una variable (1 si aparece)

	chegou	excelente	não	produto	quebrado	rápido
produto chegou quebrado	1	0	0	1	1	0
produto excelente chegou rápido	1	1	0	1	0	1
não chegou	1	0	1	0	0	0

Con los comentarios reales el vocabulario tiene 3.219 palabras (las que aparecen en al menos 5 comentarios del entrenamiento). Se usan los mismos cinco modelos y el mismo procedimiento.

Intento 2: con el texto de la reseña, los cinco modelos superan el umbral



Mejor modelo

Red neuronal MLP con dos capas ocultas (100, 50): F1 de 0,918 y 0,855.

Mismo procedimiento, otras variables

El F1 de la clase insatisfecho pasa de 0,510 a 0,855. La mejora viene de los datos, no del algoritmo.

40.775 pedidos con comentario. Sin submuestreo (35 % de insatisfechos) ni estandarización (variables binarias).

La red neuronal MLP detecta 87 % de los insatisfechos y acierta 84 % de las veces que los señala

	Predijo satisfecho	Predijo insatisfecho
Era satisfecho	**4.787**	493
Era insatisfecho	360	**2.515**

87,5 %

Recall: insatisfechos detectados
2.515 de 2.875

83,6 %

Precisión: aciertos al señalar insatisfecho
493 falsas alarmas

0,855

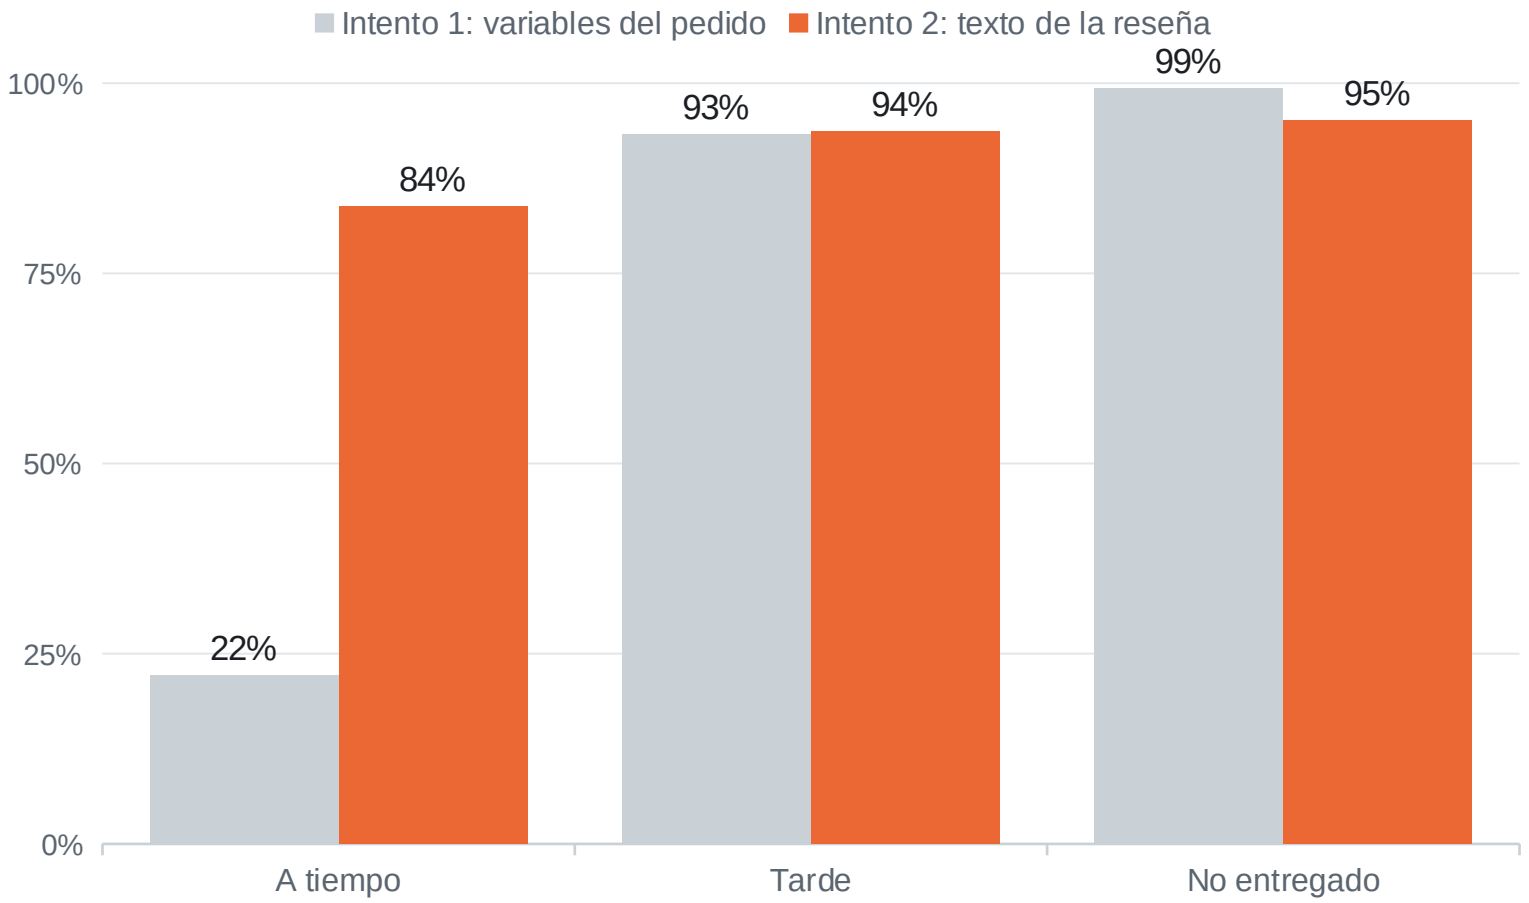
F1 de la clase insatisfecho

F1 satisfecho: 0,918

Con el intento 1, el mejor modelo detectaba 47 % de los insatisfechos y acertaba 56 % de las veces.

Conjunto de prueba. Filas: valor real. Columnas: valor predicho.

El modelo de texto también encuentra a los insatisfechos que recibieron a tiempo



A tiempo: de 22 % a 84 %

Es el grupo más grande de insatisfechos y el que el primer intento no podía ver.

En los pedidos tarde o no entregados, ambos enfoques detectan más del 90 %.

Recall de la clase insatisfecho por estado de entrega. Los conjuntos de prueba difieren: el del intento 1 incluye pedidos sin comentario.

Las palabras con más peso coinciden con las quejas encontradas en el diagnóstico

Hacia insatisfecho	Peso		Hacia satisfecho	Peso
péssima pésima	+2,90		**excelente** excelente	-2,74
atrasada atrasada	+2,58		**ótimo** óptimo	-2,52
porcaria porquería	+2,43		**otimo** óptimo, sin tilde	-2,43
péssimo pésimo	+2,39		**amei** me encantó	-2,38
pessima pésima, sin tilde	+2,25		**adorei** me encantó	-2,35
entrar de «entrar em contato»	+2,22		**show** genial	-2,33
insatisfeita insatisfecha	+2,13		**parabéns** felicitaciones	-2,22
baixa baja	+2,11		**maravilhoso** maravilloso	-2,16

Pesos de la regresión logística entrenada con el texto (F1 0,921 / 0,850). Peso positivo: aumenta la probabilidad de insatisfecho.

Recomendaciones para Olist

1	**Clasificar los comentarios al recibirlos**	Atender primero los señalados como insatisfechos (recall 87 %).
2	**Cumplir la fecha estimada de entrega**	Vigilar pedidos en riesgo y avisar al cliente antes del vencimiento.
3	**Reforzar la logística en temporada alta**	Noviembre y febrero-marzo concentran retrasos e insatisfacción.
4	**Informar los envíos separados**	Pedidos con varios vendedores: 61 % de insatisfechos.
5	**Seguimiento a vendedores y productos**	Despachos tardíos y quejas recurrentes de calidad o diferencias con el anuncio.

La mejora vino de cambiar la información de entrada, no el algoritmo

Diagnóstico	El retraso explica parte de la insatisfacción; dos tercios de los insatisfechos recibieron a tiempo y se quejan del producto.
Intento 1	Con variables del pedido, ningún modelo supera 0,7 (mejor F1 insatisfecho: 0,510). Solo detecta la insatisfacción ligada a la entrega.
Intento 2	Con el texto de la reseña, los cinco modelos superan 0,7. El mejor es la red neuronal MLP (0,918 / 0,855).

Limitaciones: solo el 41 % de los clientes comenta; la bolsa de palabras no considera el orden de las palabras (por ejemplo, "bueno, pero demoró"); los datos corresponden a Brasil entre 2016 y 2018.